

副テーマ研究計画

トークン予算統制下における AI コードレビュー・
オーケストレーション構成の欠陥検出性能比較

高原 大明

2026/07/16

概要：同一予算下で 4 構成を比較し，コスト対検出率の Pareto front を描く

研究の問い

同一トークン予算の下で，どの AI コードレビュー構成が最も費用対効果よく欠陥を検出するか．

構成の優位性は観点分割によるものか，単なる計算量増加によるものか．

- ・ 単一 / 観点別並列 / 敵対的批評 / multi-run 集約と複数の構成が提案されているが，計算コストを揃えた統制比較は存在しない
- ・ 実 OSS の既知バグを PR に再注入し，正解データを統制したベンチマークを構築する
- ・ **新規性**：国内外とも本交点の先行研究は確認できず（2026 年 7 月時点の調査）

背景：multi-agent レビューは提案が先行し，統制検証が追いついていない

- ・ 商用・研究の両面で multi-agent 型レビューの提案が急増
 - ・ 役割分担型（CodeAgent, EMNLP 2024），multi-role 欠陥検出（ICML 2025 Spotlight）など
- ・ 一方で実証研究は課題を報告
 - ・ 商用レビューエージェント 13 種中 12 種がシグナル比 60% 未満（ノイズ過多）
 - ・ 偽陽性コストを含めた評価の需要が高まっている

マルチエージェント研究全体の潮流（2025-2026）

提案フェーズ → 批判・統制検証フェーズへ移行．

一般推論ドメインでは「予算を揃えると multi-agent debate 等の優位が消える・逆転する」
との報告が複数（EMNLP 2024 ほか）

業務で AI コードレビュー基盤の設計・運用にも携わっており，
構成選択が経験則に頼っている現状に課題意識

研究ギャップ：「予算統制 × コードレビュー」の交点が空白

1. 勝因（観点分割 vs 計算量）の ablation なし 2. defect injection ベンチは商用先行で中立性がない

	一般推論ドメイン	コードレビュー
統制なし	MAD・Reflexion 等の提案群	CodeAgent / CR-Bench 等 (高々 2 構成の比較まで)
統制あり	Token Economies (EMNLP 2024) 「予算を揃えると優位が消える」	空白 — 本研究 4 構成 × 予算統制 × 実バグ再注入

→ 偽陽性コストが非対称な検出タスクで一般ドメインの知見が成り立つかを検証

研究課題：3 つの RQ で「構成の価値」と「計算量の効果」を切り分ける

RQ1 トークン予算を統制したとき，4 構成の間に欠陥検出率・偽陽性率の差があるか

RQ2 観点別並列の優位性（があるとすれば）は，同一予算の multi-run 集約
（= 純粋な計算量増加）と比較しても残るか ← 本研究の核心

RQ3 欠陥の種別（ロジック / セキュリティ / 並行性 / API 誤用など）によって
有利な構成は異なるか

実験計画：実バグの遡り再注入と予算統制で 4 構成を比較する

ベンチマーク (defect injection)

- ・ 実 OSS のバグ修正コミットを遡り「バグ入り PR」を再現 (50-100 件)
- ・ 合成バグのみの評価は検出能力を過大評価するとの報告あり → **実バグの遡り再注入**を採用
- ・ leakage 検査・バグ種別の層別を含む

比較する 4 構成 (総予算を統一)

Single	単一レビューが全観点を担当
Parallel	観点別レビューを並列に立て集約
Adversarial	レビュー + 反証する批評エージェント
Multi-run	同一プロンプト N 回の集約 (計算量統制の対照群)



評価指標：欠陥検出率・偽陽性率とコスト効率の両面から比較する

従属変数 欠陥検出率 (recall), 偽陽性率, F1
コスト効率：\$ / 検出 1 件, トークン / 検出 1 件
副次：指摘の位置精度, バグ種別ごとの検出率 (RQ3)

独立変数 レビュー構成 4 種 × モデル 2-3 種 × トークン予算 2-3 水準

発表計画：SIG-AGI 第 33 回で予備結果を発表する

2026/7/24	SIG-AGI 第 33 回 発表申込締切（タイトル + 概要のみ）
2026/8/7	原稿提出（ショート 4 ページ：問題提起 + パイロット実験）
2026/8/21	SIG-AGI 第 33 回 発表（東大本郷 + オンライン）
2026/9-12	ベンチマーク拡充・本実験

研究会で予備結果を発表して議論を集める。

